

Correction détaillée — Statistique descriptive

Calculs manuels, formules tableurs & simulations Calc

STS BIOAL — Module 5

Table des matières

1	Rappel de l'énoncé	2
2	Notation $\sum$: signification et règles de calcul	2
2.1	Que signifie le symbole $\sum$?	2
2.2	Exemple concret sur nos données	3
2.3	Règles de calcul à connaître	3
2.4	Notations abrégées utilisées dans la suite	3
2.5	Traduction dans le tableur	4
3	Mise en place des données	4
3.1	Série brute	4
3.2	Simulation de la feuille Calc	4
4	Indicateurs de position	4
4.1	Moyenne arithmétique	4
4.2	Médiane	5
4.3	Quartiles	5
5	Indicateurs de dispersion	5
5.1	Variance et écart-type (formule de König)	5
6	Histogramme des effectifs par classes	6
6.1	Construction du tableau de classes	6
6.2	Histogramme	6
6.3	Moyenne et variance par classes	6
7	Boîte à moustaches	7
8	Détection d'une valeur aberrante	7
9	Régression linéaire — illustration	7
10	Comparaison visuelle : exact vs. classes	8
11	Modus operandi — Générer les graphiques avec LibreOffice Calc	8
11.1	Préparation de la feuille	8
11.2	Histogramme des effectifs	9
11.3	Boîte à moustaches (à partir de LibreOffice 7.1)	9
11.4	Nuage de points et droite de régression	9
11.5	Coefficient de variation et tableau récapitulatif	9
12	Récapitulatif général	10

1 Rappel de l'énoncé

Contexte général

Dans le cadre du module de statistique descriptive (STS Bioanalyse), un laboratoire d'analyses médicales contrôle la concentration en glucose d'un lot de sérums. La valeur cible du fabricant est fixée à 15,5 g/L. Le technicien doit vérifier la conformité du lot et diagnostiquer d'éventuelles anomalies.

Énoncé de la partie « Bonus »

Énoncé.

On dispose de $n = 40$ mesures de concentration en glucose (en g/L) réalisées sur un même lot :

12,1	12,6	13,0	13,3	13,6	13,9	14,0	14,2	14,4	14,5
14,7	14,9	15,0	15,1	15,2	15,3	15,4	15,5	15,6	15,8
15,9	16,0	16,1	16,3	16,4	16,5	16,6	16,8	16,9	17,0
17,2	17,4	17,5	17,7	17,9	18,1	18,4	18,6	18,9	19,1

Questions bonus :

- C.1.** Calculer la moyenne exacte et l'écart-type exact à partir des valeurs brutes, puis comparer avec la méthode des classes.
- C.2.** Démontrer que la somme des écarts à la moyenne est nulle, et vérifier numériquement.
- C.3.** Démontrer l'identité de König $\sum (x_i - \bar{x})^2 = \sum x_i^2 - n\bar{x}^2$ et en déduire la variance exacte.
- C.4.** Quelle proportion des échantillons dépasse $\bar{x} + \sigma$?
- C.5.** La valeur 19,1 est-elle aberrante selon la règle de Tukey ?
- C.6.** Que deviennent moyenne, variance, écart-type et coefficient de variation si l'on convertit les concentrations en mg/dL (multiplication par 100) ?
- C.7.** Établir la relation entre les coefficients de la régression de y en x et ceux de la régression inverse de x en y .
- C.8.** Rédiger une conclusion biologique argumentée sur la conformité du lot.

2 Notation $\sum$: signification et règles de calcul

2.1 Que signifie le symbole $\sum$?

Le symbole $\sum$ (lettre grecque majuscule *sigma*) est l'opérateur de **sommation**. Il indique que l'on doit *additionner* une quantité pour toutes les valeurs d'un indice variant entre deux bornes.

Formellement :

$$\sum_{i=1}^n x_i = x_1 + x_2 + x_3 + \cdots + x_{n-1} + x_n.$$

Décomposition des éléments :

Élément	Rôle
$\sum$	« somme de ... »
$i = 1$	indice de départ (on commence à $i = 1$)
n	indice d'arrivée (on s'arrête à $i = n$)
x_i	terme général à additionner

2.2 Exemple concret sur nos données

Pour la série des 40 concentrations, l'écriture

$$\sum_{i=1}^{40} x_i$$

signifie littéralement :

$$\begin{aligned} & x_1 + x_2 + x_3 + \cdots + x_{39} + x_{40} \\ & = 12,1 + 12,6 + 13,0 + \cdots + 18,9 + 19,1 = 633,4. \end{aligned}$$

De même,

$$\sum_{i=1}^{40} x_i^2 = x_1^2 + x_2^2 + \cdots + x_{40}^2 = 12,1^2 + 12,6^2 + \cdots + 19,1^2 = 10\,151,16.$$

2.3 Règles de calcul à connaître

R1. Somme d'une constante. Si c est une constante (indépendante de i), alors :

$$\sum_{i=1}^n c = n \times c.$$

Exemple : $\sum_{i=1}^{40} 3 = 40 \times 3 = 120.$

R2. Linéarité. Pour deux suites (x_i) et (y_i) et deux constantes a, b :

$$\sum_{i=1}^n (a x_i + b y_i) = a \sum_{i=1}^n x_i + b \sum_{i=1}^n y_i.$$

R3. Factorisation d'une constante.

$$\sum_{i=1}^n (c \cdot x_i) = c \sum_{i=1}^n x_i.$$

R4. Attention ! En général :

$$\sum_{i=1}^n x_i^2 \neq \left(\sum_{i=1}^n x_i \right)^2.$$

Dans notre cas : $\sum x_i^2 = 10\,151,16$ tandis que $(\sum x_i)^2 = 633,4^2 \approx 401\,195$. Ces deux quantités sont totalement différentes !

2.4 Notations abrégées utilisées dans la suite

Par souci de lisibilité, on notera souvent :

$$\sum x_i \quad \text{pour} \quad \sum_{i=1}^n x_i, \quad \sum x_i^2 \quad \text{pour} \quad \sum_{i=1}^n x_i^2.$$

De même, pour la somme des carrés des écarts :

$$\sum (x_i - \bar{x})^2 \quad \text{signifie} \quad \sum_{i=1}^n (x_i - \bar{x})^2 = (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2.$$

2.5 Traduction dans le tableur

Dans LibreOffice Calc ou Excel, la somme $\sum x_i$ se traduit directement par la fonction :

`=SOMME(A2:A41)` (français) `=SUM(A2:A41)` (anglais)

Pour la somme des carrés $\sum x_i^2$:

`=SOMME.SQ(A2:A41)` (français) `=SUMSQ(A2:A41)` (anglais)

Ces fonctions réalisent *automatiquement* la sommation décrite par le symbole $\sum$: elles parcourent toutes les cellules de la plage A2 : A41 et additionnent leurs valeurs.

3 Mise en place des données

3.1 Série brute

Un laboratoire de bioanalyse contrôle la concentration en glucose (g/L) d'un lot de $n = 40$ échantillons sériques :

12,1	12,6	13,0	13,3	13,6	13,9	14,0	14,2	14,4	14,5
14,7	14,9	15,0	15,1	15,2	15,3	15,4	15,5	15,6	15,8
15,9	16,0	16,1	16,3	16,4	16,5	16,6	16,8	16,9	17,0
17,2	17,4	17,5	17,7	17,9	18,1	18,4	18,6	18,9	19,1

Sommes fondamentales (calculs vérifiés) :

$$\sum_{i=1}^{40} x_i = 633,4 \quad \sum_{i=1}^{40} x_i^2 = 10\,151,16$$

3.2 Simulation de la feuille Calc

On saisit les valeurs dans la colonne A :

	A	B	C	D
1	Concentration (g/L)			
2	12,1			
3	12,6			
4	13,0			
⋮	⋮			
41	19,1			
42				
43	n	<code>=NB(A2:A41)</code>	40	
44	$\bar{x}$	<code>=MOYENNE(A2:A41)</code>	15,835	
45	$\sum x_i$	<code>=SOMME(A2:A41)</code>	633,4	
46	$\sum x_i^2$	<code>=SOMME.SQ(A2:A41)</code>	10151,16	

Équivalents anglais (Excel) : `COUNT`, `AVERAGE`, `SUM`, `SUMSQ`.

4 Indicateurs de position

4.1 Moyenne arithmétique

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{633,4}{40} = \boxed{15,835 \text{ g/L}}.$$

La formule $\bar{x} = \frac{1}{n} \sum x_i$ se lit « la moyenne est égale à la somme de toutes les valeurs, divisée par leur nombre ».

4.2 Médiane

Série déjà triée, $n = 40$ (pair) : $Me = \frac{x_{20} + x_{21}}{2}$.

$$x_{20} = 15,8, \quad x_{21} = 15,9 \quad \implies \quad Me = \boxed{15,85 \text{ g/L}}.$$

4.3 Quartiles

Position : $p_k = \frac{k(n+1)}{4}$.

Pour Q_1 : $p_1 = 10,25$, donc

$$Q_1 = x_{10} + 0,25(x_{11} - x_{10}) = 14,5 + 0,25 \times 0,2 = \boxed{14,55}.$$

Pour Q_3 : $p_3 = 30,75$, donc

$$Q_3 = x_{30} + 0,75(x_{31} - x_{30}) = 17,0 + 0,75 \times 0,2 = \boxed{17,15}.$$

$$IQR = Q_3 - Q_1 = 17,15 - 14,55 = \boxed{2,60 \text{ g/L}}.$$

	A	B	C	D
48	Médiane Me	<code>=MEDIAN(A2:A41)</code>	15,85	
49	Q_1	<code>=QUARTILE.INC(A2:A41;1)</code>	14,55	
50	Q_3	<code>=QUARTILE.INC(A2:A41;3)</code>	17,15	
51	IQR	<code>=D50-D49</code>	2,60	

En anglais : `=MEDIAN(...)`, `=QUARTILE.INC(...,k)`.

5 Indicateurs de dispersion

5.1 Variance et écart-type (formule de König)

La formule de König permet de calculer la somme des carrés des écarts (SCE) sans avoir à calculer chaque écart individuellement :

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2.$$

Signification terme à terme :

- $\sum x_i^2$: somme des carrés de toutes les valeurs (calculée directement sur les données brutes) ;
- $n\bar{x}^2$: produit de l'effectif n par le carré de la moyenne.

$$V = \frac{1}{n} \left[\sum x_i^2 - n\bar{x}^2 \right] = \frac{10\,151,16 - 40 \times 15,835^2}{40}$$

$$n\bar{x}^2 = 40 \times 250,747225 = 10\,029,889$$

$$SCE = 10\,151,16 - 10\,029,889 = 121,271$$

$$V = \frac{121,271}{40} = \boxed{3,0318} \quad \sigma = \sqrt{3,0318} \approx \boxed{1,7412 \text{ g/L}}$$

Écart-type échantillonnal :

$$s^2 = \frac{SCE}{n-1} = \frac{121,271}{39} \approx 3,1095 \quad s \approx \boxed{1,7634 \text{ g/L}}$$

	A	B	C	D
53	SCE	<code>=SOMME.SQ(A2:A41)-A43*A44^2</code>	121,271	
54	V (pop.)	<code>=VAR.P(A2:A41)</code>	3,0318	
55	σ (pop.)	<code>=ECARTYPE.P(A2:A41)</code>	1,7412	
56	s^2 (éch.)	<code>=VAR.S(A2:A41)</code>	3,1095	
57	s (éch.)	<code>=ECARTYPE.S(A2:A41)</code>	1,7634	
58	Étendue	<code>=MAX(A2:A41)-MIN(A2:A41)</code>	7,0	
59	CV	<code>=ECARTYPE.P(A2:A41)/MOYENNE(A2:A41)</code>	0,1100	

6 Histogramme des effectifs par classes

6.1 Construction du tableau de classes

Classe	Centre c_i	Effectif n_i	Fréquence
[12 ; 14[	13	4	0,100
[14 ; 16[	15	17	0,425
[16 ; 18[	17	14	0,350
[18 ; 20[	19	5	0,125
Total	—	40	1,000

6.2 Histogramme




FIGURE 1 – Histogramme des effectifs par classes de largeur 2 g/L.

6.3 Moyenne et variance par classes

$$\bar{x}_{cl} = \frac{\sum n_i c_i}{\sum n_i} = \frac{4 \times 13 + 17 \times 15 + 14 \times 17 + 5 \times 19}{40} = \frac{640}{40} = \boxed{16,0}$$

$$V_{cl} = \frac{4 \cdot 9 + 17 \cdot 1 + 14 \cdot 1 + 5 \cdot 9}{40} = \frac{112}{40} = \boxed{2,8} \quad \sigma_{cl} \approx \boxed{1,6733}.$$

	A	B	C	D
61	Centre c_i	Effectif n_i		
62	13	4		
63	15	17		
64	17	14		
65	19	5		
66	$\bar{x}_{cl}$	=SOMMEPROD(A62:A65;B62:B65)/SOMME(B62:B65)	16,0	
67	V_{cl}	=SOMMEPROD(B62:B65;(A62:A65-A66)^2)/SOMME(B62:B65)	2,8	

Remarque : la méthode des classes sous-estime la variance ($V_{cl} = 2,8 < V_{exact} = 3,03$), car la dispersion interne aux classes est « perdue ».

7 Boîte à moustaches




FIGURE 2 – Boîte à moustaches. La valeur maximale 19,1 reste en deçà de la borne supérieure 21,05 : aucune valeur n'est aberrante.

8 Détection d'une valeur aberrante

Règle de Tukey : une valeur est aberrante si

$$x < Q_1 - 1,5 IQR \quad \text{ou} \quad x > Q_3 + 1,5 IQR.$$

$$Q_1 - 1,5 IQR = 14,55 - 3,90 = 10,65, \quad Q_3 + 1,5 IQR = 17,15 + 3,90 = 21,05.$$

Intervalle admissible : $[10,65 ; 21,05]$.

La valeur maximale 19,1 est *strictement* à l'intérieur : pas d'aberration.

	A	B	C	D
69	Borne inf.	=D49-1,5*D51	10,65	
70	Borne sup.	=D50+1,5*D51	21,05	
71	Aberrant ?	=SI(OU(A2<D69;A2>D70);"OUI";"NON")	NON	

9 Régression linéaire — illustration

On considère ici un exemple de droite $y = ax + b$ avec les indicateurs de qualité associés. La droite de régression de y en x a pour équation :

$$a = \frac{\text{Cov}(x, y)}{V(x)}, \quad b = \bar{y} - a\bar{x}, \quad r = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}.$$




FIGURE 3 – Exemple de nuage de points et droite de régression linéaire.

	A	B	C	D
73	Pente a	=PENTE(B2:B11;A2:A11)	1,78	
74	Ordonnée b	=ORDONNEE.ORIGINE(B2:B11;A2:A11)	1,28	
75	r	=COEFFICIENT.CORRELATION(A2:A11;B2:B11)	0,998	
76	r^2	=COEFFICIENT.DETERMINATION(B2:B11;A2:A11)	0,996	
77	$a' = 1/a$	=1/D73	0,562	
78	$b' = -b/a$	=-D74/D73	-0,719	

10 Comparaison visuelle : exact vs. classes




FIGURE 4 – Comparaison des indicateurs par calcul exact et par classes.

11 Modus operandi — Générer les graphiques avec LibreOffice Calc

11.1 Préparation de la feuille

1. Ouvrir LibreOffice Calc.
2. Saisir les 40 valeurs dans A2 : A41.
3. Ajouter les formules auxiliaires (moyenne, médiane, quartiles, écarts-types) comme indiqué dans les simulations précédentes.

11.2 Histogramme des effectifs

1. Construire le tableau des classes dans deux colonnes : $B2 : B5$ = centres (ou bornes), $C2 : C5$ = effectifs.
2. Sélectionner $B2 : C5$.
3. Menu Insertion → Graphique.
4. Type : Colonnes (ou Barres).
5. Cliquer Suivant, puis Terminer.
6. Pour transformer en histogramme : clic droit sur une barre → Écart → mettre 0 % (barres jointives).
7. Double-clic sur l'axe X → Étiquettes → choisir les bornes de classes.

11.3 Boîte à moustaches (à partir de LibreOffice 7.1)

1. Sélectionner la plage $A2 : A41$ (données brutes).
2. Insertion → Graphique.
3. Type : Boîte à moustaches.
4. Suivant / Terminer.
5. Pour afficher les valeurs : double-clic sur la boîte → onglet Étiquettes de données → cocher Afficher les valeurs.
6. Le seuil de Tukey est calculé automatiquement ; pour le modifier : clic droit → Format de la série → Options de la boîte → coefficient d'écart interquartile (défaut : 1,5).

11.4 Nuage de points et droite de régression

1. Saisir x dans $A2 : A11$ et y dans $B2 : B11$.
2. Sélectionner $A2 : B11$.
3. Insertion → Graphique → type XY (dispersion).
4. Choisir Points seuls puis Terminer.
5. Clic droit sur un point → Insérer une courbe de tendance.
6. Choisir Linéaire, cocher Afficher l'équation et Afficher R^2 .
7. Pour la droite inverse : échanger les colonnes en abscisse et en ordonnée, puis répéter.

11.5 Coefficient de variation et tableau récapitulatif

1. Ajouter une cellule $D60$: `=ECARTYPE.P(A2:A41)/MOYENNE(A2:A41)`.
2. Format → Nombre → Pourcentage.
3. Pour un récapitulatif graphique : sélectionner les cellules d'indicateurs et Insertion → Graphique → Colonnes.

12 Récapitulatif général

Indicateur	Valeur exacte	Valeur par classes
Effectif n	40	40
$\sum x_i$	633,4	—
$\sum x_i^2$	10 151,16	—
Moyenne $\bar{x}$	15,835	16,0
Médiane Me	15,85	—
Q_1	14,55	—
Q_3	17,15	—
IQR	2,60	—
Étendue	7,0	—
Variance V (pop.)	3,032	2,8
Écart-type σ	1,741	1,673
Écart-type s (éch.)	1,763	—
CV	11,0 %	10,5 %

Conclusion biologique

Le lot présente une concentration moyenne de 15,835 g/L, très proche de la cible 15,5 g/L, avec un CV d'environ 11 % indiquant une bonne homogénéité. Aucune valeur aberrante n'est détectée selon la règle de Tukey (borne supérieure : 21,05 g/L ; max observé : 19,1 g/L). Le lot peut être déclaré **conforme**.