

CORRIGÉ DU CHALLENGE STATISTIQUE

STS BIOAL – Module 5

Statistique descriptive – Classe de 40 échantillons sériques

Mode d'emploi de ce corrigé

Ce document corrige l'intégralité du Challenge statistique. Il est structuré en **trois parties** :

1. **Corrections détaillées** des 6 épreuves (calculs, justifications, pièges).
2. **Représentations graphiques** implantées à chaque fois qu'elles éclairent le propos (histogramme, courbe des FCC, boîte à moustaches, nuage de points).
3. **Guide de choix des graphiques** : quel graphique pour quelle situation ? Tableau comparatif et arbre de décision.

Convention. Les résultats sont donnés avec les arrondis demandés dans l'énoncé. Les étapes intermédiaires sont conservées pour la pédagogie. Les pièges sont signalés par un encadré rouge.

Rappel du contexte commun

Un laboratoire de bioanalyse contrôle la **concentration en glucose** (g/L) d'un lot de 40 échantillons sériques :

12,1 ; 12,6 ; 13,0 ; 13,3 ; 13,6 ; 13,9 ; 14,0 ; 14,2 ; 14,4 ; 14,5 ; 14,7 ; 14,9 ; 15,0 ; 15,1 ; 15,2 ; 15,3 ; 15,4 ; 15,5 ; 15,6 ; 15,8 ; 15,9 ; 16,0 ; 16,1 ; 16,3 ; 16,4 ; 16,5 ; 16,6 ; 16,8 ; 16,9 ; 17,0 ; 17,2 ; 17,4 ; 17,5 ; 17,7 ; 17,9 ; 18,1 ; 18,4 ; 18,6 ; 18,9 ; 19,1

CORRIGÉ 1 – Tableau statistique

(8 min – 20 pts)

1.1. Tableau complété. *Comptage des effectifs* : on parcourt la liste et on compte chaque valeur dans sa classe.

Classe	Effectif n_i	Fréquence f_i	FCC	Centre x_i
[12 ; 13[	2	0,050	0,050	12,5
[13 ; 14[	4	0,100	0,150	13,5
[14 ; 15[	6	0,150	0,300	14,5
[15 ; 16[	9	0,225	0,525	15,5
[16 ; 17[	8	0,200	0,725	16,5
[17 ; 18[	6	0,150	0,875	17,5
[18 ; 19[	4	0,100	0,975	18,5
[19 ; 20[	1	0,025	1,000	19,5
Total	40	1,000	—	—

Vérifications : $\sum n_i = 40 \checkmark$ $\sum f_i = 1,000 \checkmark$ Dernière FCC = 1,000 $\checkmark$

1.2. FCC de la classe [16 ; 17[: $F_5 = 0,725$.

Interprétation. 72,5 % des échantillons ont une concentration en glucose strictement inférieure à 17 g/L.

1.3. Proportion strictement inférieure à 15 g/L.

La valeur 15 est la borne supérieure de la classe [14 ; 15[. On lit donc la FCC de cette classe :

$$F_3 = f_1 + f_2 + f_3 = 0,050 + 0,100 + 0,150 = 0,300.$$

Réponse : 30,0 % des échantillons ont une concentration strictement inférieure à 15 g/L.


1.4. Proportion supérieure ou égale à 17 g/L.

On somme les effectifs des classes [17 ; 18[, [18 ; 19[et [19 ; 20[:

$$n = 6 + 4 + 1 = 11 \quad \Rightarrow \quad f = \frac{11}{40} = 0,275.$$

Réponse : 27,5 %. Autre méthode : $1 - F_5 = 1 - 0,725 = 0,275$.

Représentation 1 – Histogramme des effectifs (8 classes de largeur 1)




Intérêt pédagogique. L'histogramme **montre la forme de la distribution** :

- **mode** visible à $[15;16[$ (hauteur maximale) ;
- distribution **quasi symétrique** autour de la classe modale ;
- **pas d'outlier** évident (la classe $[19;20[$ n'a qu'un seul individu mais reste dans la continuité).

C'est le graphique de référence pour une variable continue regroupée en classes.


Représentation 2 – Courbe des fréquences cumulées croissantes (FCC)



Intérêt pédagogique. La courbe des FCC permet de **lire directement** Q_1 , M_e , Q_3 par interpolation linéaire, et de répondre à toute question du type « quel pourcentage a une valeur $< x$? ». C'est le **complément naturel de l'histogramme**.

CORRIGÉ 2 – Représentations graphiques**(8 min – 15 pts)****2.1. et 2.2.** Voir les deux graphiques de la page précédente (histogramme + courbe des FCC).**2.3. Détermination des cinq indicateurs.**

Indicateur	Valeur	Justification
Minimum	12,1	1 ^{re} valeur de la série ordonnée
Maximum	19,1	Dernière valeur de la série ordonnée
Médiane M_e	15,85	Moyenne des rangs 20 et 21 : $(15,8 + 15,9)/2$
Premier quartile Q_1	14,5	Rang $\lceil 40/4 \rceil = 10$
Troisième quartile Q_3	17,0	Rang $\lceil 3 \times 40/4 \rceil = 30$

2.4. Boîte à moustaches. Placement des 5 valeurs : min = 12,1 ; $Q_1 = 14,5$; $M_e = 15,85$; $Q_3 = 17,0$; max = 19,1.**2.5. Symétrie.** On compare les deux demi-boîtes et les deux moustaches :

- $M_e - Q_1 = 15,85 - 14,5 = 1,35$ et $Q_3 - M_e = 17,0 - 15,85 = 1,15$: **écarts proches** ;
- moustache gauche : $Q_1 - \min = 14,5 - 12,1 = 2,4$ et moustache droite : $\max - Q_3 = 19,1 - 17,0 = 2,1$: **longueurs proches**.

Conclusion. La distribution est **approximativement symétrique** (léger étalement vers la gauche, mais négligeable).

CORRIGÉ 3 – Indicateurs de position

(8 min – 20 pts)

3.1. Moyenne. On calcule d'abord $\sum n_i x_i$ à partir des centres de classes.

Classe	x_i	n_i	$n_i x_i$
[12 ; 13[	12,5	2	25,0
[13 ; 14[	13,5	4	54,0
[14 ; 15[	14,5	6	87,0
[15 ; 16[	15,5	9	139,5
[16 ; 17[	16,5	8	132,0
[17 ; 18[	17,5	6	105,0
[18 ; 19[	18,5	4	74,0
[19 ; 20[	19,5	1	19,5
Total	—	40	$\sum n_i x_i = 636,0$

$$\bar{x} = \frac{\sum n_i x_i}{N} = \frac{636,0}{40} = 15,90 \text{ g/L}$$

3.2. Médiane. On utilise les rangs. $N = 40$ est *pair*, donc :

$$M_e = \frac{\text{valeur de rang 20} + \text{valeur de rang 21}}{2}.$$

La série ordonnée comporte (cumul) : rangs 1–2 : [12 ; 13[; rangs 3–6 : [13 ; 14[; rangs 7–12 : [14 ; 15[; rangs 13–21 : [15 ; 16[.

Les rangs 20 et 21 tombent tous deux dans la classe [15 ; 16[: rang 20 = 15,8, rang 21 = 15,9.

$$M_e = \frac{15,8 + 15,9}{2} = 15,85 \text{ g/L}$$

3.3. Quartiles.

— Q_1 : rang $\lceil N/4 \rceil = 10 \Rightarrow Q_1 = 14,5 \text{ g/L}$.

Signification concrète : 25 % des échantillons ont une concentration inférieure ou égale à 14,5 g/L (et 75 % supérieure ou égale).

— Q_3 : rang $\lceil 3N/4 \rceil = 30 \Rightarrow Q_3 = 17,0 \text{ g/L}$.

3.4. Mode et classe modale.

— Il s'agit d'une série **continue regroupée en classes** : le mode est une **classe modale**.

— La classe de plus grand effectif est [15 ; 16[avec $n = 9$.

— Classe modale : [15 ; 16[. Il n'y a pas de mode unique (valeur ponctuelle), mais une classe modale unique.

3.5. Vrai/Faux.

— « Comme la moyenne et la médiane sont proches, la distribution est approximativement symétrique. »

VRAI. $\bar{x} = 15,90$ et $M_e = 15,85$: l'écart est de 0,05, négligeable. Ceci confirme la lecture de la boîte à moustaches (question 2.5). *Attention* : une proximité moyenne/médiane est une *condition nécessaire* mais non suffisante ; elle doit être confirmée par l'histogramme.

— « 50 % des échantillons ont une concentration comprise entre Q_1 et Q_3 . »

VRAI. Par définition, Q_1 et Q_3 encadrent les 50 % centraux de la population. Ici : $14,5 \leq x \leq 17,0$ contient 50 % des valeurs.

CORRIGÉ 4 – Indicateurs de dispersion

(7 min – 15 pts)

4.1. Étendue.

$$E = \max - \min = 19,1 - 12,1 = 7,0 \text{ g/L}$$

4.2. Écart interquartile.

$$I_Q = Q_3 - Q_1 = 17,0 - 14,5 = 2,5 \text{ g/L}$$

4.3. Variance et écart-type. On utilise la formule rapide $V = \frac{1}{N} \sum n_i x_i^2 - \bar{x}^2$.

Classe	x_i	n_i	x_i^2	$n_i x_i^2$
[12 ; 13[	12,5	2	156,25	312,50
[13 ; 14[	13,5	4	182,25	729,00
[14 ; 15[	14,5	6	210,25	1 261,50
[15 ; 16[	15,5	9	240,25	2 162,25
[16 ; 17[	16,5	8	272,25	2 178,00
[17 ; 18[	17,5	6	306,25	1 837,50
[18 ; 19[	18,5	4	342,25	1 369,00
[19 ; 20[	19,5	1	380,25	380,25
Total	—	40	—	10 230,0

$$V = \frac{10\,230,0}{40} - (15,90)^2 = 255,75 - 252,81 = 2,94$$

$$V \approx 2,94 \text{ (g/L)}^2$$

$$\sigma = \sqrt{2,94} \approx 1,715 \text{ g/L}$$

4.4. Interprétation de l'écart-type.

« En moyenne, les concentrations en glucose des 40 échantillons s'écartent d'environ 1,7 g/L de la concentration moyenne (15,90 g/L). »

Cette valeur traduit l'homogénéité du lot : un écart-type faible par rapport à la moyenne ($\sigma/\bar{x} \approx 10,8\%$) indique un lot *relativement homogène*, sans grande variabilité.

CORRIGÉ 5 – Ajustement affine et corrélation**(12 min – 20 pts)****5.1. Moyennes.**

$$\bar{x} = \frac{0 + 2 + 4 + 6 + 8 + 10}{6} = \frac{30}{6} = 5,00$$

$$\bar{y} = \frac{0,05 + 0,22 + 0,38 + 0,57 + 0,71 + 0,90}{6} = \frac{2,83}{6} \approx 0,4717$$

5.2. Sommes. On construit un tableau de calcul.

i	x_i	y_i	x_i^2	y_i^2	$x_i y_i$
1	0	0,05	0	0,0025	0
2	2	0,22	4	0,0484	0,44
3	4	0,38	16	0,1444	1,52
4	6	0,57	36	0,3249	3,42
5	8	0,71	64	0,5041	5,68
6	10	0,90	100	0,8100	9,00
Total	$\sum x_i = 30$	$\sum y_i = 2,83$	220	1,8343	20,06

5.3. Droite de régression $y = ax + b$.*Covariance :*

$$\text{Cov}(x, y) = \frac{\sum x_i y_i}{N} - \bar{x} \bar{y} = \frac{20,06}{6} - 5 \times 0,4717 = 3,3433 - 2,3585 = 0,9848$$

Variances :

$$V(x) = \frac{220}{6} - 5^2 = 36,6667 - 25 = 11,6667$$

$$V(y) = \frac{1,8343}{6} - (0,4717)^2 = 0,3057 - 0,2225 = 0,0832$$

Coefficients :

$$a = \frac{\text{Cov}(x, y)}{V(x)} = \frac{0,9848}{11,6667} \approx 0,0844$$

$$b = \bar{y} - a\bar{x} = 0,4717 - 0,0844 \times 5 = 0,4717 - 0,4220 \approx 0,050$$

$$\boxed{y = 0,0844x + 0,050}$$

5.4. Coefficient de corrélation linéaire.

$$r = \frac{\text{Cov}(x, y)}{\sqrt{V(x) V(y)}} = \frac{0,9848}{\sqrt{11,6667 \times 0,0832}} = \frac{0,9848}{0,9855} \approx 0,999$$

$$\boxed{r \approx 0,999}$$

5.5. Adéquation du modèle linéaire.


$|r| = 0,999$ est **très proche de 1** : la liaison linéaire entre la concentration et l'absorbance est **quasi parfaite**. Le modèle linéaire est donc **parfaitement adapté**.

Vérification graphique (voir nuage de points ci-dessous) : les 6 points sont presque exactement alignés.

5.6. Application. Pour $y = 0,80$:

$$0,80 = 0,0844x + 0,050 \quad \Rightarrow \quad x = \frac{0,80 - 0,050}{0,0844} \approx 8,89$$

$$\boxed{x \approx 8,89 \text{ g/L}}$$

Représentation 3 – Nuage de points et droite de régression $y = 0,0844x + 0,050$ 

Intérêt pédagogique. Le nuage de points est le **graphique indispensable** pour :

- **vérifier la linéarité** avant tout calcul de régression ;
- **repérer les outliers** (points très éloignés de la tendance) ;
- **visualiser l'étalonnage** et lire une valeur inconnue (ici, la flèche en pointillés montre la lecture pour $y = 0,80$).

CORRIGÉ 6 – Utilisation du tableur

(7 min – 10 pts)

Formules exactes à saisir (plage A2:A41) :

Question	Fonction	Formule exacte
a. Effectif total	NB	=NB(A2:A41)
b. Moyenne	MOYENNE	=MOYENNE(A2:A41)
c. Médiane	MEDIANE	=MEDIANE(A2:A41)
d. Premier quartile Q_1	QUARTILE	=QUARTILE(A2:A41;1)
e. Troisième quartile Q_3	QUARTILE	=QUARTILE(A2:A41;3)
f. Écart-type	ECARTYPE	=ECARTYPE(A2:A41)
g. Minimum	MIN	=MIN(A2:A41)
h. Maximum	MAX	=MAX(A2:A41)

Remarque. Selon la version d'Excel, on peut aussi écrire =QUARTILE.INCLURE(A2:A41;1) (qui donne le même résultat que QUARTILE). Pour l'écart-type d'une *population*, utiliser =ECARTYPEP(A2:A41).

i. Deux méthodes pour tracer une boîte à moustaches.

1. **Méthode manuelle** : calculer séparément min, Q_1 , M_e , Q_3 , max (via les fonctions précédentes), puis construire le graphique à la main ou avec l'outil « graphique en chandeliers » (*stock chart*).
2. **Méthode automatique** : sélectionner la plage A2:A41, puis Insertion > Graphiques > Boîte à moustaches (Excel 2016 et versions ultérieures). Dans LibreOffice Calc : Insertion > Graphique > Boîte à moustaches.

j. Recopie vers le bas.

- En C1, on a saisi =MOYENNE(A2:A41).
- En recopiant vers C2, on obtient =MOYENNE(A3:A42).
- **Le résultat n'est pas pertinent** : la plage se décale automatiquement (référence *relative*), et les cellules A3:A42 ne correspondent plus à la série (perte de la première valeur, prise en compte d'une cellule vide ou parasite).
- **Solution** : utiliser des **références absolues** en ancrant les bornes avec le symbole \$:

=MOYENNE(\$A\$2:\$A\$41)

Ainsi, la recopie en C2, C3... conserve la plage correcte.

Guide de choix des représentations graphiques

Quel graphique pour quelle situation ? Synthèse pédagogique.

Tableau comparatif des graphiques

Graphique	Type de variable	Ce qu'il montre	Intérêt principal	Limites
Bâtons	Qualitative ou quantitative discrète	Effectif / fréquence de chaque modalité	Compare les catégories ; repère le mode	Inadapté aux variables continues
Circulaire	Qualitative (peu de modalités)	Part de chaque catégorie dans le total	Vision « composition » parlante	Illisible au-delà de 6-7 modalités
Histogramme	Quantitative continue (classes)	Forme de la distribution (symétrie, mode, outliers)	Révèle la structure globale ; oriente le choix moyenne/médiane	Sensible au choix des classes
Courbe des FCC	Quantitative (discrète ou continue)	Cumul des fréquences ; lecture directe de M_e , Q_1 , Q_3	Répond à « quel % est $< x$? » ; complément de l'histogramme	Moins visuelle seule
Boîte à moustaches	Quantitative (une ou plusieurs séries)	5 indicateurs : min, Q_1 , M_e , Q_3 , max ; outliers	Compare plusieurs séries en un coup d'œil ; robuste	Ne montre pas la forme exacte (bimodalité invisible)
Nuage de points + droite	Deux variables quantitatives	Liaison entre deux variables ; tendance linéaire	Prédiction, étalonnage ; détection d'outliers et de non-linéarité	r ne mesure que la linéarité

Arbre de décision – Quel graphique choisir ?

1. **Une seule variable, qualitative ou discrète ?** → Diagramme en bâtons (ou circulaire si peu de modalités et objectif de composition).
2. **Une seule variable, quantitative continue ?**
 - Pour voir la *forme* de la distribution → **Histogramme**.
 - Pour lire M_e , Q_1 , Q_3 sans calcul → **Courbe des FCC**.
 - Pour *comparer plusieurs séries* → **Boîtes à moustaches juxtaposées**.
3. **Deux variables quantitatives ?** → **Nuage de points**, puis droite de régression si la tendance est linéaire.
4. **Règle d'or** : *toujours tracer d'abord, calculer ensuite*. Un graphique mal choisi peut masquer une information essentielle.

Quel graphique pour notre sujet ? Réponses concrètes

- Pour montrer la répartition des 40 concentrations → **histogramme** (Représentation 1).
- Pour lire directement M_e , Q_1 , Q_3 → **courbe des FCC** (Représentation 2).
- Pour visualiser la dispersion et la symétrie → **boîte à moustaches** (voir question 2.4).

- Pour l'étalonnage du spectrophotomètre → nuage de points + droite de régression (Représentation 3).
- Pour comparer plusieurs lots (non demandé ici, mais utile) → boîtes à moustaches juxtaposées.

⚠ Pièges classiques à éviter

- **Histogramme vs diagramme en bâtons** : l'histogramme a des barres *jointives* (variable continue) ; le diagramme en bâtons a des barres *séparées* (variable discrète ou qualitative).
- **Aires proportionnelles** : dans un histogramme, ce sont les *aires* qui sont proportionnelles aux effectifs, pas les hauteurs (sauf si les classes ont même amplitude).
- **Courbe des FCC** : elle est *toujours croissante*, de 0 à 1. Une courbe qui descend signale une erreur de calcul.
- **Boîte à moustaches** : elle *ne montre pas* la forme exacte de la distribution. Deux séries très différentes (unimodale vs bimodale) peuvent avoir la même boîte.
- **Nuage de points** : toujours le tracer *avant* de calculer r . Un $r \approx 0$ n'exclut pas une relation non linéaire (parabole, exponentielle...).
- r **proche de 1** : ne prouve pas une relation de *causalité*, seulement une corrélation *linéaire* forte.

Récapitulatif des résultats numériques

Tous les résultats en un coup d'œil

Épreuve	Quantité	Résultat
1	Effectifs n_i	2 ; 4 ; 6 ; 9 ; 8 ; 6 ; 4 ; 1
	FCC de $[16 ; 17[$	0,725
	Proportion < 15 g/L	30,0 %
	Proportion ≥ 17 g/L	27,5 %
2 et 3	Minimum	12,1 g/L
	Maximum	19,1 g/L
	Médiane M_e	15,85 g/L
	Premier quartile Q_1	14,5 g/L
	Troisième quartile Q_3	17,0 g/L
3	Moyenne $\bar{x}$	15,90 g/L
	Mode	Classe $[15 ; 16[$
	Symétrie	approximativement symétrique
4	Étendue	7,0 g/L
	Écart interquartile I_Q	2,5 g/L
	Variance V / écart-type σ	2,94 / 1,715 g/L
5	Moyennes	$\bar{x} = 5,00$; $\bar{y} = 0,4717$
	Pente a / ordonnée b	0,0844 / 0,050
	Coefficient r	0,999
	Estimation pour $y = 0,80$	$x \approx 8,89$ g/L
6	Point critique	Références absolues $\$A\$2:\$A\41

Pour conclure : deux leçons méthodologiques

Leçon 1. *Toujours tracer les données avant de calculer.* Histogramme, boîte à moustaches et nuage de points sont vos trois alliés. Ce sont eux qui révèlent la forme de la distribution, les outliers et la linéarité — toutes choses qu'aucune formule ne peut remplacer.

Leçon 2. *Choisir le bon indicateur selon la situation.* Sur une distribution symétrique sans outlier (cas de ce sujet), moyenne et médiane racontent la même histoire. Sur une distribution asymétrique ou avec outliers, seuls la médiane et l'écart interquartile sont fiables.

« Un graphique vaut mille tableaux ; un bon graphique vaut mille calculs. »