

CHALLENGE STATISTIQUE

STS BIOAL – Module 5

Statistique descriptive

Règles du jeu

- **Format** : équipes de **3 ou 4 étudiants**.
- **Durée totale** : **50 minutes** (chronométrées, épreuve par épreuve).
- **6 épreuves – 100 points** au total.
- **Matériel autorisé** : calculatrice, tableur (ordinateur), papier millimétré, règle.
- **Barème** : les points sont attribués par épreuve selon les critères indiqués. En cas d'égalité, l'équipe ayant terminé la dernière épreuve en premier gagne.
- Chaque équipe remet **une seule feuille-réponse** par épreuve.

Épreuve	Thème	Durée	Barème
1	Effectifs, fréquences, fréquences cumulées	8 min	20 pts
2	Diagrammes, histogramme, boîte à moustaches	8 min	15 pts
3	Indicateurs de position	8 min	20 pts
4	Indicateurs de dispersion	7 min	15 pts
5	Ajustement affine et corrélation	12 min	20 pts
6	Utilisation du tableur	7 min	10 pts
TOTAL		50 min	100 pts

Contexte commun à toutes les épreuves

Un laboratoire de **bioanalyse** contrôle la **concentration en glucose** (en g/L) d'un lot de 40 échantillons sériques. Les résultats obtenus sont les suivants :

12,1 ; 12,6 ; 13,0 ; 13,3 ; 13,6 ; 13,9 ; 14,0 ; 14,2 ; 14,4 ; 14,5 ; 14,7 ; 14,9 ; 15,0 ; 15,1 ; 15,2 ; 15,3 ;
 15,4 ; 15,5 ; 15,6 ; 15,8 ; 15,9 ; 16,0 ; 16,1 ; 16,3 ; 16,4 ; 16,5 ; 16,6 ; 16,8 ; 16,9 ; 17,0 ; 17,2 ; 17,4 ;
 17,5 ; 17,7 ; 17,9 ; 18,1 ; 18,4 ; 18,6 ; 18,9 ; 19,1

ÉPREUVE 1 – Tableau statistique

(8 min – 20 pts)

On regroupe les 40 valeurs en **8 classes** de largeur 1 g/L : $[12; 13[$, $[13; 14[$, ..., $[19; 20[$.

1.1. Compléter le tableau ci-dessous (arrondir les fréquences à 10^{-3}) :

Classe	Effectif n_i	Fréquence f_i	Fréq. cumulée croissante	Centre x_i
$[12; 13[$				12,5
$[13; 14[$				
$[14; 15[$				
$[15; 16[$				
$[16; 17[$				
$[17; 18[$				
$[18; 19[$				
$[19; 20[$				
Total	40	1	—	—

1.2. Quelle est la **fréquence cumulée croissante** de la classe $[16; 17[$? Interpréter en une phrase.

1.3. Quelle proportion d'échantillons a une concentration **strictement inférieure à 15 g/L** ? Exprimer en % (arrondi à 0,1 %).

1.4. Quelle proportion a une concentration **supérieure ou égale à 17 g/L** ?

ÉPREUVE 2 – Représentations graphiques**(8 min – 15 pts)**


2.1. Sur le papier millimétré fourni, tracer l'**histogramme** des effectifs (classes de largeur 1, donc hauteurs = effectifs).

2.2. Tracer la **courbe des fréquences cumulées croissantes** sur le même graphique (utiliser les bornes supérieures des classes comme abscisses).

2.3. À partir du tableau de l'épreuve 1, déterminer :

- le **minimum** :
- le **maximum** :
- la **médiane** M_e :
- le **premier quartile** Q_1 :
- le **troisième quartile** Q_3 :

2.4. Tracer la **boîte à moustaches** (diagramme en boîte) correspondante sur l'axe gradué ci-dessous :



2.5. D'après la boîte à moustaches, la distribution est-elle symétrique ? Justifier.

ÉPREUVE 3 – Indicateurs de position

(8 min – 20 pts)

- 3.1. Calculer la **moyenne** $\bar{x}$ de la série (à partir des centres de classes). Arrondir à 10^{-2} .
- 3.2. Déterminer la **médiane** M_e . Justifier brièvement la méthode utilisée (position dans la série ordonnée).
- 3.3. Déterminer Q_1 et Q_3 . Rappeler la signification concrète de Q_1 .
- 3.4. Quel est le **mode** de la série ? S'agit-il d'un mode unique ? Préciser la **classe modale**.
- 3.5. **Vrai/Faux** – justifier :
- « Comme la moyenne et la médiane sont proches, la distribution est approximativement symétrique. »
 - « 50 % des échantillons ont une concentration comprise entre Q_1 et Q_3 . »

ÉPREUVE 4 – Indicateurs de dispersion

(7 min – 15 pts)

- 4.1. Calculer l'**étendue** de la série.
- 4.2. Calculer l'**écart interquartile** $I_Q = Q_3 - Q_1$.
- 4.3. Calculer la **variance** V et l'**écart-type** σ de la série (à partir des centres de classes). Arrondir V à 10^{-2} et σ à 10^{-3} .
- Aide : on rappelle que $V = \frac{1}{N} \sum_{i=1}^k n_i x_i^2 - \bar{x}^2$.
- 4.4. Interpréter l'écart-type en une phrase (que mesure-t-il concrètement ici ?).

ÉPREUVE 5 – Ajustement affine et corrélation

(12 min – 20 pts)

Pour **étalonner** un spectrophotomètre, le laboratoire prépare 6 solutions de glucose de concentrations connues et mesure l'absorbance :

Concentration x_i (g/L)	0	2	4	6	8	10
Absorbance y_i	0,05	0,22	0,38	0,57	0,71	0,90

5.1. Calculer les moyennes $\bar{x}$ et $\bar{y}$.

5.2. Calculer les sommes suivantes : $\sum x_i^2$, $\sum y_i^2$, $\sum x_i y_i$.

5.3. Déterminer par la **méthode des moindres carrés** l'équation de la droite de régression $y = ax + b$ (arrondir a à 10^{-4} et b à 10^{-3}).

5.4. Calculer le **coefficient de corrélation linéaire** r (arrondi à 10^{-3}).

5.5. Le modèle linéaire est-il adapté ? Justifier à l'aide de r .

5.6. *Application* : on mesure une absorbance de 0,80. Estimer la concentration en glucose de l'échantillon (arrondie à 10^{-2} g/L).

ÉPREUVE 6 – Utilisation du tableur

(7 min – 10 pts)

Sur la feuille de calcul, les concentrations sont saisies dans la plage A2:A41.

Écrire la **formule exacte** à saisir pour obtenir :

Question	Formule
a. L'effectif total	
b. La moyenne	
c. La médiane	
d. Le premier quartile Q_1	
e. Le troisième quartile Q_3	
f. L'écart-type	
g. Le minimum	
h. Le maximum	

i. Citer deux méthodes pour tracer une **boîte à moustaches** à partir d'une série de données.

j. Après avoir entré la formule =MOYENNE(A2:A41) dans la cellule C1, on la recopie vers le bas en C2. Quelle formule obtient-on ? Le résultat est-il pertinent ? Que faire ?

Feuille de score de l'équipe

Identification de l'équipe

Nom de l'équipe : _____

Capitaine : _____

Membres :

1. _____

2. _____

3. _____

4. _____

Grille des scores

Épreuve	Barème	Score	Observations
1 – Tableau statistique	/20		
2 – Représentations graphiques	/15		
3 – Indicateurs de position	/20		
4 – Indicateurs de dispersion	/15		
5 – Ajustement affine et corrélation	/20		
6 – Utilisation du tableur	/10		
TOTAL	/100		

Deux citations pour méditer sur la statistique

1. La formule anglaise de Ronald Coase (économiste, prix Nobel 1991) :

« *If you torture the data long enough, it will confess.* »

— Ronald Coase, années 1960

Traduction française :

« *Si vous torturez les données assez longtemps, elles avoueront.* »

Première trace écrite : en 1971, dans une allocution du mathématicien britannique **Irving John Good**, qui l'attribue explicitement à Coase.

2. La variante française antérieure d'Alfred Sauvy (démographe, 1898–1990) :

« *Les chiffres sont des innocents qui, sous la sollicitation, sous la torture, avouent très vite ce qu'on leur demande, quitte à se rétracter plus tard.* »

— Alfred Sauvy, L'Opinion publique, 1961

En résumé. Toutes deux rappellent que les chiffres peuvent être manipulés et qu'il faut se méfier des conclusions hâtives.

Annexe A – Vignettes de cours

À consulter à tout moment pendant l'épreuve.

📖 V1 – Vocabulaire de base

Population : ensemble étudié.

Individu : élément de la population.

Caractère : ce que l'on mesure (quantitatif ou qualitatif).

Série statistique : liste des valeurs observées.

Effectif n_i : nombre d'individus de la modalité i .

Effectif total : $N = \sum n_i$.

Fréquence : $f_i = \frac{n_i}{N}$, avec $\sum f_i = 1$.

Fréquence cumulée croissante (FCC) : $F_i = f_1 + f_2 + \dots + f_i$.

La dernière FCC vaut toujours 1.

📖 V2 – Classes et centres de classes

Pour une série **continue** (ou très nombreuse), on regroupe les valeurs en **classes** $[a; b[$.

Centre de classe : $x_i = \frac{a+b}{2}$.

Amplitude : $b - a$ (constante si classes régulières).

On remplace chaque valeur par le centre de sa classe pour les calculs.

📖 V3 – Représentations graphiques

Diagramme en bâtons : effectifs ou fréquences (série discrète).

Histogramme : classes en abscisse, *aires proportionnelles* aux effectifs.

Classes de même amplitude $\Rightarrow$ hauteur = effectif.

Courbe des FCC : en abscisse les bornes supérieures, en ordonnée les fréquences cumulées. Toujours croissante, de 0 à 1.

Boîte à moustaches : représente min, Q_1 , M_e , Q_3 , max.

📖 V4 – Indicateurs de position

Moyenne : $\bar{x} = \frac{1}{N} \sum_{i=1}^k n_i x_i$.

Médiane M_e : valeur qui partage la série ordonnée en deux moitiés (50 % / 50 %).

Quartiles : Q_1 (25 %), M_e (50 %), Q_3 (75 %).

Mode : valeur (ou classe) de plus grand effectif.

📖 V5 – Indicateurs de dispersion

Étendue : max – min.

Écart interquartile : $I_Q = Q_3 - Q_1$.

Variance : $V = \frac{1}{N} \sum n_i (x_i - \bar{x})^2 = \frac{1}{N} \sum n_i x_i^2 - \bar{x}^2$.

Écart-type : $\sigma = \sqrt{V}$ (même unité que x).

📖 V6 – Ajustement affine et corrélation

Nuage de points $(x_i; y_i)$.

Droite de régression : $y = ax + b$ (moindres carrés).

Covariance : $\text{Cov}(x, y) = \frac{1}{N} \sum x_i y_i - \bar{x} \bar{y}$.

Coefficient de corrélation linéaire : $r = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$.

Propriété : $-1 \leq r \leq 1$.

$|r|$ proche de 1 $\Rightarrow$ forte corrélation linéaire.

V7 – Choisir entre (moyenne ; écart-type) et (médiane ; écart interquartile)

Deux couples d'indicateurs pour résumer une série quantitative :

- **Couple paramétrique** : moyenne $\bar{x}$ et écart-type σ (ou variance V).
- **Couple robuste** : médiane M_e et écart interquartile $I_Q = Q_3 - Q_1$.

Rôle spécifique de chaque couple.

- **Moyenne** $\bar{x}$: centre de gravité de la série ; utilise toutes les valeurs. Elle indique la valeur moyenne.
- **Écart-type** σ : dispersion moyenne autour de $\bar{x}$; même unité que la variable. Plus σ est grand, plus les valeurs sont hétérogènes.
- **Médiane** M_e : valeur qui partage la série ordonnée en deux moitiés (50 % en dessous, 50 % au-dessus). Elle décrit une valeur typique, peu sensible aux extrêmes.
- **Écart interquartile** I_Q : étendue de la moitié centrale des données (entre Q_1 et Q_3). Il mesure la dispersion robuste, sans être influencé par les valeurs extrêmes.

Différences et similarités.

Critère	Couple (moyenne ; écart-type)	Couple (médiane ; interquartile)
Nature	Paramétrique, algébrique	Robuste, non paramétrique
Sensibilité aux extrêmes	Très sensible	Peu sensible
Information utilisée	Toutes les valeurs	Rangs centraux (50 % central)
Distribution idéale	Symétrique, sans outlier, unimodale	Asymétrique ou avec outliers
Position	Centre de gravité $\bar{x}$	Valeur de rang 50 % M_e
Dispersion	Écart moyen à la moyenne σ	Étendue des 50 % centraux I_Q
Interprétation	$\bar{x} \pm \sigma$ (si symétrie)	$M_e [Q_1 ; Q_3]$
Usage typique	Calculs, régression, tests paramétriques	Description robuste, tests non paramétriques
Similarité	Les deux couples résument position et dispersion, dans l'unité de la variable. Si la distribution est symétrique et sans outlier, $\bar{x} \approx M_e$ et $\sigma \approx I_Q/1,35$.	

Quand utiliser l'un plutôt que l'autre ?

- **Utiliser moyenne + écart-type** si :
 - distribution approximativement symétrique (histogramme en cloche) ;
 - absence de valeurs aberrantes ;
 - besoin de calculs ultérieurs (variance, régression, tests paramétriques) ;
 - variable quantitative continue, mesures fiables.
- **Utiliser médiane + écart interquartile** si :
 - distribution asymétrique (ex. concentrations biologiques, temps d'attente) ;
 - présence de valeurs extrêmes ou aberrantes ;
 - effectif faible ou variable ordinale ;
 - on veut décrire la moitié centrale sans être trompé par les extrêmes.
- **Cas où ils sont interchangeables** : lorsque la distribution est symétrique, unimodale et sans outlier (proche d'une loi normale). Alors $\bar{x} \approx M_e$ et $\sigma \approx I_Q/1,35$; les deux couples donnent le même message. En pratique, on préfère souvent $\bar{x}$ et σ car ils utilisent toute l'information et se prêtent mieux aux calculs. Mais ils ne sont jamais totalement interchangeables pour les tests ou en présence d'asymétrie.

À retenir. Toujours tracer un histogramme ou une boîte à moustaches avant de choisir. Si $\bar{x}$ et M_e sont proches et que la distribution est symétrique, les deux couples sont cohérents. Si $\bar{x}$ s'éloigne de M_e ou si la boîte à moustaches montre des outliers, privilégier M_e et I_Q .

Annexe B – Vignettes méthodes

Procédures pas-à-pas à appliquer pendant l'épreuve.

✂ M1 – Construire un tableau statistique

1. Choisir les classes (souvent de même amplitude).
2. Compter les effectifs n_i (par comptage ou tableau).
3. Calculer chaque fréquence $f_i = n_i/N$.
4. Calculer les FCC en cumulant les f_i .
5. Calculer les centres $x_i = (a + b)/2$.
6. Vérifier : $\sum n_i = N$ et $\sum f_i = 1$.

✂ M2 – Calculer moyenne et écart-type

1. Construire le tableau : $n_i, x_i, n_i x_i, n_i x_i^2$.
2. Moyenne : $\bar{x} = \frac{\sum n_i x_i}{N}$.
3. $V = \frac{\sum n_i x_i^2}{N} - \bar{x}^2$.
4. $\sigma = \sqrt{V}$.
5. Arrondir à la fin *seulement*.

✂ M3 – Trouver médiane et quartiles

Cas discret (série ordonnée de N valeurs) :

- M_e : si N impair, rang $\frac{N+1}{2}$; si N pair, moyenne des rangs $\frac{N}{2}$ et $\frac{N}{2} + 1$.
- Q_1 : valeur de rang $\lceil N/4 \rceil$.
- Q_3 : valeur de rang $\lceil 3N/4 \rceil$.

Cas regroupé en classes : utiliser la **courbe des FCC**. On lit l'abscisse pour $y = 0,25, 0,5, 0,75$.

✂ M4 – Tracer une boîte à moustaches

1. Tracer un axe gradué avec l'unité de la variable.
2. Placer min, Q_1 , M_e , Q_3 , max.
3. Dessiner le rectangle $[Q_1 ; Q_3]$.
4. Tracer un trait vertical à M_e .
5. Relier min à Q_1 et Q_3 à max.

Lecture : boîte centrée + moustaches égales $\Rightarrow$ symétrie.

✂ M5 – Ajustement affine par moindres carrés

1. Calculer $\bar{x}$ et $\bar{y}$.
2. Calculer $\sum x_i^2, \sum y_i^2, \sum x_i y_i$.
3. $\text{Cov}(x, y) = \frac{\sum x_i y_i}{N} - \bar{x}\bar{y}$.
4. $V(x) = \frac{\sum x_i^2}{N} - \bar{x}^2$; $V(y) = \frac{\sum y_i^2}{N} - \bar{y}^2$.
5. $a = \frac{\text{Cov}(x, y)}{V(x)}$; $b = \bar{y} - a\bar{x}$.
6. $r = \frac{\text{Cov}(x, y)}{\sqrt{V(x)V(y)}}$.

✂ M6 – Utiliser un tableur

Fonctions utiles (plage A2:A41) :

- =NB(A2:A41) – effectif
- =MOYENNE(A2:A41) – moyenne
- =MEDIANE(A2:A41) – médiane
- =QUARTILE(A2:A41;1) – Q_1
- =QUARTILE(A2:A41;3) – Q_3
- =ECARTYPE(A2:A41) – écart-type
- =MIN(...) / =MAX(...)

Piège : lors d'une recopie vers le bas, la plage se décale (A3:A42). Utiliser des références absolues : \$A\$2:\$A\$41.

Annexe C – Formulaire récapitulatif

Effectif total : $N = \sum n_i$

Fréquence : $f_i = n_i/N$

FCC : $F_i = \sum_{j \leq i} f_j$

Centre de classe : $x_i = (a + b)/2$

Moyenne : $\bar{x} = \frac{1}{N} \sum n_i x_i$

Variance : $V = \frac{1}{N} \sum n_i x_i^2 - \bar{x}^2$

Écart-type : $\sigma = \sqrt{V}$

Étendue : $E = \max - \min$

Écart interquartile : $I_Q = Q_3 - Q_1$

Covariance : $\text{Cov} = \frac{1}{N} \sum x_i y_i - \bar{x} \bar{y}$

Pente : $a = \text{Cov}(x, y)/V(x)$

Ordonnée : $b = \bar{y} - a \bar{x}$


Corrélation : $r = \text{Cov}(x, y)/(\sigma_x \sigma_y)$

Annexe D – Vignettes d'exemples de diagrammes

Exemples illustratifs **indépendants du sujet** : ils servent à comprendre chaque type de représentation, sans donner d'éléments de réponse.

📖 D1 – Diagramme en bâtons (variable discrète)

Exemple : nombre de colonies observées sur 25 boîtes de Petri.




Lecture : chaque barre correspond à une valeur *unique* de la variable.

Quand l'utiliser : variable quantitative *discrète* (comptage) ou qualitative.

Intérêt : visualise immédiatement **la fréquence de chaque modalité**, permet d'identifier le **mode** d'un seul coup d'œil et de comparer rapidement les catégories entre elles. Idéal pour les petits effectifs et les variables qualitatives.

📖 D2 – Diagramme circulaire (secteurs)

Répartition de 20 échantillons en 5 catégories (A : 30 %, B : 25 %, C : 20 %, D : 15 %, E : 10 %).




Lecture : l'angle de chaque secteur est proportionnel à la fréquence : $\theta_i = f_i \times 360^\circ$.

Quand l'utiliser : caractère qualitatif à peu de modalités.

Intérêt : met en évidence la **part de chaque catégorie dans le total** (composition d'une population). Très parlant pour le grand public, il permet de comparer visuellement des proportions. Attention : peu lisible au-delà de 6 ou 7 modalités.

📖 D3 – Histogramme (classes jointives)

Exemple : longueur de feuilles (mm) mesurée sur 50 plantules (contexte totalement différent du sujet).




Lecture : les classes sont *jointives* (pas d'espace entre les barres).

Règle d'or : les *aires* des rectangles sont proportionnelles aux effectifs. Si les classes ont même amplitude, hauteur = effectif ; sinon, hauteur = $n_i / \text{amplitude}_i$.

Intérêt : outil privilégié pour une **variable continue regroupée en classes**. Il révèle la **forme de la distribution** : symétrie, asymétrie, unimodalité, bimodalité, présence de valeurs aberrantes. C'est le point de départ pour choisir entre moyenne et médiane.

📖 D4 – Courbe des fréquences cumulées croissantes (FCC)

Même exemple que D3 : longueur de feuilles (mm), $N = 50$.




Lecture : on lit M_e , Q_1 , Q_3 en projetant les niveaux 0,50 ; 0,25 ; 0,75 sur l'axe des abscisses.

Propriété : la courbe est toujours croissante, de 0 à 1.

Intérêt : permet de **lire directement** la médiane et les quartiles (sans calcul) et de répondre à toute question du type « quel pourcentage a une valeur inférieure à x ? ». Complément naturel de l'histogramme.

📖 D5 – Boîte à moustaches (diagramme en boîte)

Exemple : taux d'hémoglobine (g/dL) dans une cohorte de patients (contexte distinct du sujet).



Lecture : la boîte contient 50 % des valeurs (entre Q_1 et Q_3). La longueur des moustaches révèle l'asymétrie.


Ici : $M_e - Q_1 = 1,3$ et $Q_3 - M_e = 1,3 \Rightarrow$ distribution quasi symétrique.

Intérêt : résume en une seule figure 5 indicateurs (min, Q_1 , M_e , Q_3 , max). Permet de comparer

plusieurs séries côte à côte et de repérer les outliers (points au-delà des moustaches). Idéal pour une première analyse rapide.

📖 D6 – Nuage de points et droite de régression (cas favorable)

Exemple : longueur (cm) et masse fraîche (g) de 6 plantules (contexte distinct du sujet).




Lecture : les points sont presque alignés $\Rightarrow |r|$ proche de 1. On peut estimer une valeur inconnue en lisant sur la droite.

Cas favorable : nuage allongé selon une direction rectiligne.

Intérêt : visualise la **liaison entre deux variables quantitatives**. Permet de **vérifier la linéarité** avant tout calcul de régression, de **repérer les outliers** et de **prédire** une valeur y pour un x donné (interpolation) ou inversement (étalonnage).

⚠️ D7 – Piège 1 : relation non linéaire (parabole)

Exemple volontairement piégeux : y dépend fortement de x , mais **pas linéairement**.




Constat : le nuage dessine clairement une **parabole** (relation en U). Pourtant $r \approx 0$ car la droite de régression est quasi horizontale.

Leçon : un r proche de 0 **ne prouve pas** l'absence de lien entre x et y : il prouve seulement l'absence de lien *linéaire*.

Reflexe : **toujours tracer le nuage** avant de calculer r .

⚠️ D8 – Piège 2 : absence totale de corrélation

Exemple : deux variables totalement indépendantes (aucune tendance).




Constat : nuage en « nuage », sans direction privilégiée. r très proche de 0.

Leçon : la droite de régression passe par le centre du nuage mais **ne résume rien**. Toute prévision à partir de cette droite serait **dépourvue de sens**.

Reflexe : si $|r| < 0,5$, ne pas utiliser de modèle linéaire pour prévoir.

⚠ D9 – Piège 3 : point aberrant

Exemple : 7 points parfaitement alignés sur $y = 2x$, + 1 point aberrant.



Constat : un **seul point** aberrant (le point situé très en dessous de la tendance) suffit à :

- « aplatir » la pente (a passe de 2 à 1,29) ;
- dégrader fortement le coefficient de corrélation (r passe de 1 à 0,66) ;
- fausser toute prévision faite avec cette droite.

Leçon : avant tout calcul, **repérer visuellement les points aberrants**. Vérifier s'il s'agit d'une erreur de saisie ou d'une valeur biologique exceptionnelle à traiter séparément.

Reflexe : tracer systématiquement le nuage et comparer la droite « avec » et « sans » les points suspects.

Annexe D bis – Tableau comparatif des graphiques

Synthèse : quel graphique choisir, pour quel type de données, avec quels avantages et limites.

Choisir le bon graphique

Graphique	Type de variable	Ce qu'il montre	Intérêt principal	Limites / précautions
Bâtons (D1)	Qualitative ou quantitative discrète	Effectif / fréquence de chaque modalité	Compare rapidement les catégories; repère le mode	Peu adapté aux variables continues
Circulaire (D2)	Qualitative (peu de modalités)	Part de chaque catégorie dans le total	Vision « composition » très parlante pour un public non spécialiste	Difficile à lire au-delà de 6–7 modalités; compare mal deux séries
Histogramme (D3)	Quantitative continue (regroupée en classes)	Forme de la distribution (symétrie, mode, outliers)	Révèle la structure globale; oriente le choix moyenne/médiane	Sensible au choix des classes (amplitude, bornes)
Courbe des FCC (D4)	Quantitative (discrète ou continue)	Cumul des fréquences; lecture directe de M_e , Q_1 , Q_3	Répond à « quel % est inférieur à x ? »; complément de l'histogramme	Moins visuelle seule; ne montre pas la forme
Boîte à moustaches (D5)	Quantitative (une ou plusieurs séries)	5 indicateurs : min, Q_1 , M_e , Q_3 , max; outliers	Compare plusieurs séries en un coup d'œil; robuste	Ne montre pas la forme exacte (bimodalité invisible)
Nuage de points + droite (D6)	Deux variables quantitatives (x , y)	Liaison entre deux variables; tendance linéaire	Prédiction, étalonnage; détection d'outliers et de non-linéarité	Nécessite de tracer le nuage <i>avant</i> de calculer r ; r ne mesure que la linéarité

D10 – Quel graphique pour quel objectif? (arbre de décision simplifié)

1. **Une seule variable, qualitative ou discrète ?** → Diagramme en bâtons (ou circulaire si peu de modalités).
2. **Une seule variable, quantitative continue ?**
 - Pour voir la *forme* de la distribution → Histogramme.
 - Pour lire M_e , Q_1 , Q_3 sans calcul → Courbe des FCC.
 - Pour *comparer plusieurs séries* → Boîtes à moustaches juxtaposées.
3. **Deux variables quantitatives ?** → Nuage de points, puis, si la tendance est linéaire, droite de régression.
4. **Toujours vérifier** : tracer d'abord, calculer ensuite. Un graphique mal choisi peut masquer une information essentielle.

Annexe E – Vignettes « grilles de calcul semi-manuel »

Grilles prêtes à remplir, dimensionnées selon les données exactes de la compétition. Les formules à appliquer sont rappelées dans les vignettes méthodes de l'Annexe B.

✂ E1 – Grille $\bar{x}$, V , σ (8 classes de l'épreuve 1)

Nombre de lignes utiles : **8** (une par classe $[12; 13[$ à $[19; 20[$). Formules : voir la vignette **M2**.

i	Classe	x_i	n_i	$n_i x_i$	x_i^2	$n_i x_i^2$	FCC
1	$[12; 13[$	12,5					
2	$[13; 14[$	13,5					
3	$[14; 15[$	14,5					
4	$[15; 16[$	15,5					
5	$[16; 17[$	16,5					
6	$[17; 18[$	17,5					
7	$[18; 19[$	18,5					
8	$[19; 20[$	19,5					
Total		—	$N = 40$	$\sum n_i x_i =$	—	$\sum n_i x_i^2 =$	1

✂ E2 – Grille sur les 40 valeurs brutes (pré-transcrites)

Nombre de lignes utiles : **40** (les 40 valeurs du contexte commun, déjà pré-remplies pour éviter toute erreur de recopie). Formules : voir la vignette **M2**.

i	x_i	x_i^2		i	x_i	x_i^2
1	12,1			21	15,9	
2	12,6			22	16,0	
3	13,0			23	16,1	
4	13,3			24	16,3	
5	13,6			25	16,4	
6	13,9			26	16,5	
7	14,0			27	16,6	
8	14,2			28	16,8	
9	14,4			29	16,9	
10	14,5			30	17,0	
11	14,7			31	17,2	
12	14,9			32	17,4	
13	15,0			33	17,5	
14	15,1			34	17,7	
15	15,2			35	17,9	
16	15,3			36	18,1	
17	15,4			37	18,4	
18	15,5			38	18,6	
19	15,6			39	18,9	
20	15,8			40	19,1	
$\sum_{i=1}^{20} x_i =$		$\sum_{i=1}^{20} x_i^2 =$		$\sum_{i=21}^{40} x_i =$	$\sum_{i=21}^{40} x_i^2 =$	

✂ E3 – Grille bivariée $\bar{x}$, $\bar{y}$, $V(x)$, $V(y)$, $\text{Cov}(x, y)$, r (6 points de l'épreuve 5)

Nombre de lignes utiles : 6 (les 6 couples $(x_i; y_i)$ de l'étalonnage). Formules : voir la vignette M5.

i	x_i	y_i	x_i^2	y_i^2	$x_i y_i$
1	0	0,05			
2	2	0,22			
3	4	0,38			
4	6	0,57			
5	8	0,71			
6	10	0,90			
Total	$\sum x_i =$	$\sum y_i =$	$\sum x_i^2 =$	$\sum y_i^2 =$	$\sum x_i y_i =$

✂ E4 – Grille d'interpolation pour Q_1 , M_e , Q_3 (8 classes)

Nombre de lignes utiles : 3 (les 3 indicateurs à déterminer). Méthode : voir la vignette M3.

Indicateur	Niveau	Classe	a	b	F_{i-1}	f_i
Q_1	0,25					
M_e	0,50					
Q_3	0,75					

✂ E5 – Récapitulatif des sommes et résultats

Nombre de lignes utiles : **17** (une par quantité à calculer). Pour chaque quantité, le rôle, l'intérêt et l'interprétation sont précisés.

Quantité	Rôle, intérêt et interprétation	Valeur calculée
Effectif total N	Rôle : base de tous les calculs (moyennes, variances). Intérêt : vérifier la cohérence des données. Interprétation : nombre total d'observations (ici $N = 40$).	
$\sum x_i$	Rôle : nécessaire pour calculer $\bar{x}$. Intérêt : permet de vérifier les calculs. Interprétation : somme brute des concentrations.	
$\sum x_i^2$	Rôle : utilisée dans la formule rapide de la variance. Intérêt : évite de calculer les écarts à la moyenne. Interprétation : grandeur liée à la dispersion et à la moyenne quadratique.	
$\bar{x}$	Rôle : indicateur de position centrale. Intérêt : résume la tendance centrale de x . Interprétation : concentration moyenne en glucose.	
$V(x)$	Rôle : mesure la dispersion autour de la moyenne. Intérêt : quantifie l'hétérogénéité des valeurs. Interprétation : plus $V(x)$ est grande, plus les valeurs sont dispersées.	
$\sigma_x = \sqrt{V(x)}$	Rôle : mesure de dispersion dans la même unité que x . Intérêt : interprétable directement. Interprétation : écart moyen à la moyenne.	
$\sum y_i$	Rôle : pour calculer $\bar{y}$. Intérêt : calcul de la moyenne des absorbances. Interprétation : somme brute des absorbances.	
$\sum y_i^2$	Rôle : pour calculer $V(y)$. Intérêt : évite les écarts à la moyenne. Interprétation : lié à la dispersion des absorbances.	
$\sum x_i y_i$	Rôle : pour calculer la covariance. Intérêt : mesure la liaison entre x et y . Interprétation : si positive, x et y varient dans le même sens.	
$\bar{y}$	Rôle : position centrale de y . Intérêt : nécessaire pour la droite de régression. Interprétation : absorbance moyenne.	
$V(y)$	Rôle : dispersion de y . Intérêt : calcul de σ_y et de r . Interprétation : variabilité des absorbances.	
$\sigma_y = \sqrt{V(y)}$	Rôle : dispersion de y dans son unité. Intérêt : pour le calcul de r . Interprétation : écart moyen des absorbances à la moyenne.	
$\text{Cov}(x, y)$	Rôle : mesure la variation conjointe de x et y . Intérêt : signe indique le sens de la relation, valeur pour calculer a et r . Interprétation : si > 0 , relation positive ; si < 0 , négative ; si proche de 0, pas de relation linéaire.	
Coefficient (pente) a	Rôle : quantifie la variation de y quand x augmente de 1 unité. Intérêt : permet de prédire y à partir de x . Interprétation : augmentation d'absorbance par g/L de glucose.	
Coefficient b (ordonnée)	Rôle : valeur de y quand $x = 0$. Intérêt : ajustement de la droite. Interprétation : absorbance théorique pour concentration nulle (souvent proche de 0, mais peut être décalage).	
Coefficient r	Rôle : mesure la force de la liaison linéaire entre x et y . Intérêt : évaluer la qualité de l'ajustement linéaire. Interprétation : entre -1 et 1 ; $ r $ proche de 1 indique une forte corrélation linéaire ; proche de 0, pas de corrélation linéaire.	
Équation de la droite	Rôle : modèle de prédiction. Intérêt : estimer y pour un x donné ou inversement. Interprétation : outil d'étalonnage.	$y =$

Annexe F – Lexique des termes statistiques

Tableau à double colonne : terme technique et définition. Les termes sont classés par ordre alphabétique. Le tableau se poursuit sur la page suivante si nécessaire.

Terme	Définition
Amplitude (d'une classe)	Différence entre la borne supérieure et la borne inférieure d'une classe : $b - a$. Constante si les classes sont régulières.
Boîte à moustaches	Représentation graphique qui résume une série par 5 valeurs : min, Q_1 , M_e , Q_3 , max.
Caractère	Ce que l'on mesure sur un individu : quantitatif (numérique) ou qualitatif (catégorie).
Centre de classe	Milieu d'une classe $[a; b[$: $x_i = (a + b)/2$. Utilisé comme représentant de la classe dans les calculs.
Classe	Intervalle $[a; b[$ regroupant les valeurs d'une série continue ou nombreuse.
Classe modale	Classe (dans une série regroupée) qui a le plus grand effectif.
Coefficient de corrélation linéaire (r)	Nombre entre -1 et 1 qui mesure la force et le sens de la liaison <i>linéaire</i> entre deux variables. $ r $ proche de 1 = forte corrélation ; proche de 0 = pas de corrélation linéaire.
Covariance	Mesure de la variation conjointe de deux variables : $\text{Cov}(x, y) = \frac{1}{N} \sum x_i y_i - \bar{x} \bar{y}$. Son signe indique le sens de la relation.
Diagramme circulaire	Représentation en secteurs dont l'angle est proportionnel à la fréquence : $\theta_i = f_i \times 360^\circ$. Utilisé pour un caractère qualitatif.
Diagramme en bâtons	Représentation par barres verticales pour une variable discrète ou qualitative.
Distribution	Manière dont les valeurs d'une série se répartissent (forme, centre, dispersion).
Écart interquartile (I_Q)	Différence entre le troisième et le premier quartile : $I_Q = Q_3 - Q_1$. Mesure la dispersion des 50 % centraux. Robuste aux valeurs extrêmes.
Écart-type (σ)	Racine carrée de la variance : $\sigma = \sqrt{V}$. Exprimé dans la même unité que la variable. Mesure la dispersion moyenne autour de la moyenne.
Effectif (n_i)	Nombre d'individus d'une modalité ou d'une classe.
Effectif total (N)	Somme de tous les effectifs : $N = \sum n_i$.
Étendue	Différence entre le maximum et le minimum : $\text{max} - \text{min}$.
Fréquence (f_i)	Proportion d'individus dans une modalité : $f_i = n_i/N$. La somme des fréquences vaut 1.
Fréquence cumulée croissante (FCC)	Somme des fréquences jusqu'à une modalité donnée : $F_i = f_1 + f_2 + \dots + f_i$. La dernière FCC vaut toujours 1.
Histogramme	Représentation graphique pour une variable continue : rectangles jointifs dont l'aire est proportionnelle à l'effectif.
Individu	Élément de la population étudiée (ici, un échantillon sériel).
Interpolation linéaire	Méthode pour estimer une valeur (ex. Q_1) à l'intérieur d'une classe à partir de la courbe des FCC ou de la formule $x = a + (b - a) \frac{p - F_{i-1}}{f_i}$.
Médiane (M_e)	Valeur qui partage la série ordonnée en deux moitiés : 50 % en dessous, 50 % au-dessus. Robuste aux valeurs extrêmes.
Mode	Valeur (ou classe) de plus grand effectif. Une série peut avoir plusieurs modes.
Moindres carrés	Méthode qui détermine la droite $y = ax + b$ minimisant la somme des carrés des écarts verticaux entre points et droite.
Moyenne ($\bar{x}$)	Somme de toutes les valeurs divisée par l'effectif total : $\bar{x} = \frac{1}{N} \sum n_i x_i$. Sensible aux valeurs extrêmes.
Suite du lexique page suivante...	

Terme	Définition
Non paramétrique	Se dit d'une méthode qui ne suppose pas de forme particulière pour la distribution (ex. médiane, quartiles).
Nuage de points	Représentation graphique des couples $(x_i ; y_i)$ dans le plan.
Outlier (valeur aberrante)	Valeur très éloignée des autres, qui peut fausser la moyenne, l'écart-type et la corrélation. À repérer sur un graphique avant tout calcul.
Paramétrique	Se dit d'une méthode qui suppose une forme de distribution (souvent normale) et utilise moyenne et écart-type.
Population	Ensemble complet des individus étudiés.
Premier quartile (Q_1)	Valeur telle que 25 % des données lui sont inférieures ou égales.
Quartiles	Les trois valeurs Q_1 , M_e , Q_3 qui partagent la série ordonnée en quatre parties égales (25 % chacune).
Régression linéaire	Ajustement d'une droite $y = ax + b$ à un nuage de points par la méthode des moindres carrés.
Robuste	Se dit d'un indicateur peu sensible aux valeurs extrêmes (ex. médiane, écart interquartile).
Série statistique	Liste des valeurs observées d'un caractère sur une population.
Symétrie (d'une distribution)	Propriété d'une distribution dont le côté gauche est l'image miroir du côté droit. Se lit sur la boîte à moustaches ou l'histogramme.
Troisième quartile (Q_3)	Valeur telle que 75 % des données lui sont inférieures ou égales.
Valeur aberrante	Voir <i>outlier</i> .
Variance (V)	Moyenne des carrés des écarts à la moyenne : $V = \frac{1}{N} \sum n_i (x_i - \bar{x})^2 = \frac{1}{N} \sum n_i x_i^2 - \bar{x}^2$.

F1 – Repères mnémotechniques

- **Moyenne et écart-type** : couple « sensible » ; utile si distribution symétrique sans outlier.
- **Médiane et écart interquartile** : couple « robuste » ; à préférer si distribution asymétrique ou avec outliers.
- **Paramétrique** = suppose une loi (normale) ; **non paramétrique** = ne suppose rien.
- **Outlier** = valeur aberrante ; à repérer *avant* tout calcul.
- **Corrélation** (r) mesure un lien *linéaire* uniquement : $r \approx 0$ n'exclut pas un lien non linéaire (ex. parabole).
- **Moindres carrés** = méthode pour trouver la « meilleure » droite $y = ax + b$.